



Mühendislik ve Doğa Bilimleri Fakültesi

Bilgisayar Mühendisliği

BİL-485 Derin Öğrenme Dersi

Görsel Üzerinden Araç Hasar Tahmini Yapan Derin Öğrenme Modeli Eğitimi Projesi

Öğrencinin;

Ad-Soyad: Seferhan KAYA

No: 22120205048

Öğretmenin;

Ad-Soyad: Dr. Öğr. Üyesi İshak DÖLEK

İÇİNDEKİLER

İÇİNDEKİLER	2
ŞEKİLLER TABLOSU	3
1. PROJE KONUSU	4
1.1. Proje Konusunun Seçilme Gerekçesi	4
1.2. Daha Önce İlgili Alanda Yapılan Uygulamalar	4
1.3. İlgili Alanın Önemi	4
2. VERİ SETİNİN BELİRLENMESİ	5
2.1. Veri Setinin İçeriği	5
2.2. Veri Setinin İçeriği	5
2.3. Ön İşleme ve Veri Artırma	5
3. UYGULANACAK YÖNTEM / ALGORİTMA / YAKLAŞIMIN SEÇİM GEREKÇESİ	6
3.1. Kullanılan Yaklaşım	6
3.2. Literatürde Kullanılan Yöntemlerle Karşılaştırma	6
3.3. Model Mimarisi ve Eğitim Stratejisi	6
4. MODEL EĞİTİMİ & MODEL DEĞERLENDİRİLMESİ	7
4.1. Model Eğitimi	7
4.2. Değerlendirme Metrikleri	7
4.3. Test Sonuçları	8
4.4. Sonuçların Yorumlanması	8
KAYNAKÇA	9

ŞEKİLLER TABLOSU

Şekil 1. Modelin Eğitimi	7
Şekil 2. Modeli Gradio Arayüzü İle Test.....	8

1. PROJE KONUSU

1.1. Proje Konusunun Seçilme Gerekçesi

Bu projede, araç görüntülerinden **hasarlı ve hasarsız durumun otomatik olarak tespit edilmesi** hedeflenmiştir. Araç hasar tespiti; sigorta süreçleri, oto ekspertiz hizmetleri ve ikinci el araç piyasasında kritik bir öneme sahiptir. Günümüzde bu değerlendirmeler çoğunlukla insan uzmanlar tarafından yapılmakta olup, zaman alıcı ve subjektif sonuçlara yol açabilmektedir [1].

Son yıllarda derin öğrenme tabanlı görüntü işleme yöntemleri, özellikle **Convolutional Neural Networks (CNN)**, bu tür problemlerde yüksek başarı göstermektedir [2]. Görsel verilerin doğrudan işlenebilmesi ve manuel özellik çıkarımına ihtiyaç duyulmaması, bu yaklaşımın tercih edilmesinde etkili olmuştur. Ayrıca problemin gerçek hayatla doğrudan ilişkili olması ve veri erişiminin mümkün olması, proje konusunun seçilmesinde belirleyici olmuştur.

1.2. Daha Önce İlgili Alanda Yapılan Uygulamalar

Literatürde araç hasar tespiti üzerine yapılan çalışmalarda ağırlıklı olarak CNN tabanlı yaklaşımlar kullanılmıştır. Bu çalışmalarda bazı araştırmacılar hasarın yalnızca varlığını tespit ederken, bazıları hasar türünü veya hasarlı bölgeyi belirlemeye odaklanmıştır [3].

Birçok çalışmada transfer learning yöntemleri kullanılarak önceden eğitilmiş derin ağlar üzerinden yüksek doğruluk oranları elde edilmiştir [4]. Ancak bu projede, ders kapsamında model mimarisinin daha iyi anlaşılması ve öğrenme sürecinin kontrol edilebilmesi amacıyla **model sıfırdan eğitilmiştir**.

1.3. İlgili Alanın Önemi

Otomatik araç hasar tespiti sistemleri, manuel değerlendirme süreçlerine kıyasla daha hızlı, tutarlı ve ölçeklenebilir çözümler sunmaktadır. Bu tür sistemlerin kullanımı, değerlendirme maliyetlerini düşürmekte ve insan kaynaklı hataları azaltmaktadır [5]. Bu nedenle geliştirilen model, pratik uygulamalar açısından önemli bir potansiyele sahiptir.

2. VERİ SETİNİN BELİRLENMESİ

2.1. Veri Setinin İçeriği

Bu çalışmada kullanılan veri seti, araçların **hasarlı (damaged)** ve **hasarsız (undamaged)** durumlarını gösteren görüntülerden oluşmaktadır. Problem, ikili sınıflandırma (binary classification) olarak ele alınmıştır.

2.2. Veri Setinin İçeriği

Veri seti eğitim, doğrulama ve test olmak üzere üç alt kümeye ayrılmıştır:

- **Eğitim seti:**
 - 920 hasarlı
 - 920 hasarsız
- **Doğrulama (validation) seti:**
 - 115 hasarlı
 - 115 hasarsız
- **Test seti:**
 - 115 hasarlı
 - 115 hasarsız

Sınıflar arasında dengeli bir dağılım sağlanarak modelin tek bir sınıfa yönelmesi engellenmiştir.

2.3. Ön İşleme ve Veri Artırma

Tüm görüntüler modele girdi olarak verilmeden önce yeniden boyutlandırılmış ve normalize edilmiştir. Eğitim sırasında modelin genelleme yeteneğini artırmak ve aşırı öğrenmeyi önlemek amacıyla veri artırma teknikleri uygulanmıştır. Bu teknikler literatürde yaygın olarak kullanılan yöntemlerdir [6].

3. UYGULANACAK YÖNTEM / ALGORİTMA / YAKLAŞIMIN SEÇİM GEREKÇESİ

3.1. Kullanılan Yaklaşım

Bu projede görüntü sınıflandırma problemi için **Convolutional Neural Network (CNN)** tabanlı bir model kullanılmıştır. CNN'ler, görüntülerdeki düşük seviyeli ve yüksek seviyeli özellikleri hiyerarşik olarak öğrenebilen yapılardır [2].

3.2. Literatürde Kullanılan Yöntemlerle Karşılaştırma

Literatürde araç hasar tespiti için kullanılan yöntemler genel olarak üç grupta incelenebilir:

- Klasik makine öğrenmesi yöntemleri (SVM, KNN)
- Transfer learning tabanlı derin öğrenme modelleri
- Sıfırdan eğitilen CNN modelleri

Klasik yöntemler manuel özellik çıkarımı gerektirdiğinden görüntü tabanlı problemler için sınırlı kalmaktadır [1]. Transfer learning yöntemleri yüksek doğruluk sunsa da, bu projede eğitim sürecinin tamamının kontrol edilebilmesi amacıyla **sıfırdan CNN eğitimi** tercih edilmiştir.

3.3. Model Mimarisi ve Eğitim Stratejisi

Model; evrişim katmanları, havuzlama katmanları ve tam bağlantılı katmanlardan oluşmaktadır. Aktivasyon fonksiyonu olarak **ReLU**, kayıp fonksiyonu olarak **Binary Cross Entropy**, optimizasyon algoritması olarak ise **AdamW** kullanılmıştır. Bu yapı literatürde önerilen standart CNN mimarileriyle uyumludur [7].

4. MODEL EĞİTİMİ & MODEL DEĞERLENDİRİLMESİ

4.1. Model Eğitimi

Model, eğitim verisi kullanılarak belirlenen epoch sayısı boyunca eğitilmiştir. Eğitim sürecinde doğrulama seti üzerinden performans izlenmiş ve en yüksek doğrulama başarımı sağlayan model kaydedilmiştir. Bu yaklaşım, modelin aşırı öğrenmesini önlemek için yaygın olarak kullanılmaktadır [8].

```
Epoch 01 | val_loss=0.7872 | val_acc=54.35%  
✓ Saved best model (val_acc=54.35%)  
Epoch 02 | val_loss=0.6913 | val_acc=56.96%  
✓ Saved best model (val_acc=56.96%)  
Epoch 03 | val_loss=0.6030 | val_acc=63.04%  
✓ Saved best model (val_acc=63.04%)  
Epoch 04 | val_loss=0.5064 | val_acc=74.78%  
✓ Saved best model (val_acc=74.78%)  
Epoch 05 | val_loss=0.6908 | val_acc=62.17%  
Epoch 06 | val_loss=1.0152 | val_acc=56.96%  
Epoch 07 | val_loss=0.4719 | val_acc=77.39%  
✓ Saved best model (val_acc=77.39%)  
Epoch 08 | val_loss=0.4528 | val_acc=79.57%  
✓ Saved best model (val_acc=79.57%)  
Epoch 09 | val_loss=0.4169 | val_acc=81.74%  
✓ Saved best model (val_acc=81.74%)  
Epoch 10 | val_loss=0.6311 | val_acc=66.96%  
Epoch 11 | val_loss=0.3852 | val_acc=83.04%  
✓ Saved best model (val_acc=83.04%)  
Epoch 12 | val_loss=0.6085 | val_acc=74.35%  
Epoch 13 | val_loss=0.5295 | val_acc=77.83%  
Epoch 14 | val_loss=0.4550 | val_acc=78.70%  
Epoch 15 | val_loss=0.6931 | val_acc=72.61%  
TEST@0.50 | loss=0.3580 | acc=86.52% | P=86.84% R=86.09% F1=86.46% | CM={'tp': 99, 'fp': 15, 'tn': 100, 'fn': 16}  
BEST TH (VAL) = 0.39 | acc=83.48% | P=78.10% R=93.04% F1=84.92% | CM={'tp': 107, 'fp': 30, 'tn': 85, 'fn': 8}  
TEST@0.39 | loss=0.3580 | acc=85.22% | P=80.45% R=93.04% F1=86.29% | CM={'tp': 107, 'fp': 26, 'tn': 89, 'fn': 8}
```

Şekil 1. Modelin Eğitimi

4.2. Değerlendirme Metrikleri

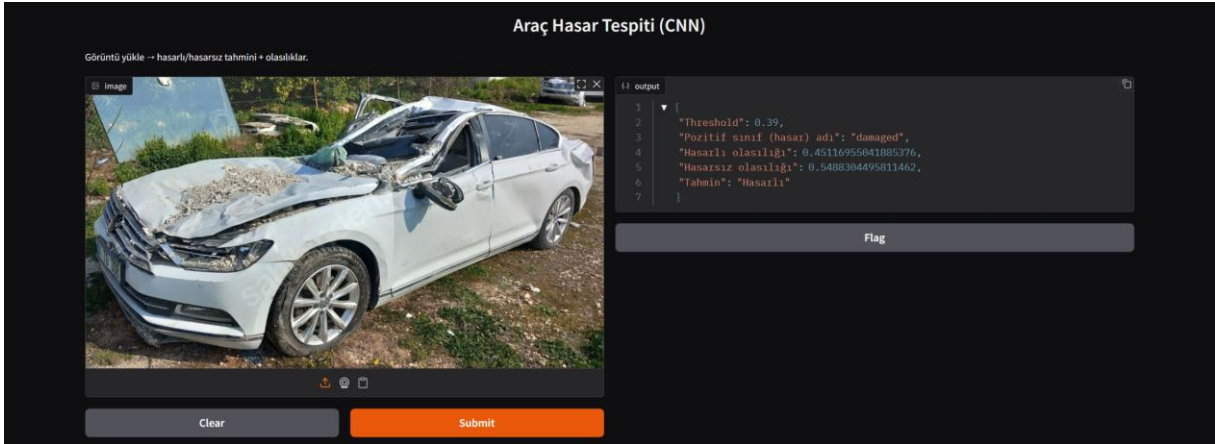
Model performansı yalnızca doğruluk (accuracy) ile değil; **precision**, **recall**, **F1-score** ve **confusion matrix** gibi metriklerle değerlendirilmiştir. Bu metrikler, özellikle dengesiz hata maliyetlerinin olduğu problemlerde daha sağlıklı analiz yapılmasını sağlamaktadır [9].

4.3. Test Sonuçları

Test seti üzerinde elde edilen sonuçlar şu şekildedir:

- Accuracy: **%86.52**
- Precision (Hasarlı): **%86.84**
- Recall (Hasarlı): **%86.09**
- F1-score: **%86.46**

Ayrıca karar eşiği 0.39 olarak ayarlanmış ve bu durumda hasarlı araçların tespit oranı **%93.04 recall** değerine ulaşmıştır.



Şekil 2. Modeli Gradio Arayüzü İle Test[10]

4.4. Sonuçların Yorumlanması

Elde edilen sonuçlar, geliştirilen CNN modelinin araç hasar tespiti probleminde başarılı bir performans sergilediğini göstermektedir. Confusion matrix analizi, modelin her iki sınıfı da yüksek oranda doğru ayırt edebildiğini ortaya koymaktadır.

KAYNAKÇA

- [1] T. Hastie, R. Tibshirani, and J. Friedman, *The Elements of Statistical Learning*, Springer, 2009.
- [2] Y. LeCun, Y. Bengio, and G. Hinton, “Deep learning,” *Nature*, vol. 521, no. 7553, pp. 436–444, 2015.
- [3] S. Dhieb et al., “Automated vehicle damage detection using deep learning,” *IEEE Access*, vol. 8, pp. 162169–162182, 2020.
- [4] A. Krizhevsky, I. Sutskever, and G. Hinton, “ImageNet classification with deep convolutional neural networks,” *Advances in Neural Information Processing Systems*, 2012.
- [5] M. R. Alam et al., “Vision-based damage detection for vehicles,” *Expert Systems with Applications*, vol. 42, no. 7, pp. 3677–3686, 2015.
- [6] L. Perez and J. Wang, “The effectiveness of data augmentation in image classification using deep learning,” *arXiv preprint arXiv:1712.04621*, 2017.
- [7] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*, MIT Press, 2016.
- [8] S. Raschka, *Machine Learning with PyTorch and Scikit-Learn*, Packt Publishing, 2022.
- [9] D. M. Powers, “Evaluation: From precision, recall and F-measure to ROC,” *Journal of Machine Learning Technologies*, 2011.
- [10] Gradio, “Gradio Documentation,” 2024. [Online] <https://www.gradio.app/docs>.
- [11] Kaggle, “Car Damage Detection Dataset,” 2025. [Online] <https://www.kaggle.com/datasets/anujms/car-damage-detection>.